



Алексей Мазуренко

AI ENGINEER / LLM ENGINEER

КОНТАКТЫ

ТЕЛЕФОН
+7 (977) 270-09-30

EMAIL
lyakoway@gmail.com

ФОРМАТ
офис / гибрид / удалённо

САЙТ
lyakoway.vercel.app/contacts

ОБО МНЕ

- **AI-инженер** с 7+ годами коммерческого опыта в разработке ПО и сильной software engineering базой. Основной фокус — LLM-приложения, RAG-системы, AI-агенты и автоматизация рабочих процессов с помощью AI.
- **Создаю AI-продукты полного цикла** — от исследования задачи и проектирования AI-архитектуры до разработки, оценки качества, интеграции и вывода решения в production.
- **Работаю с реальными сценариями применения LLM:** поиск и работа с корпоративными знаниями, анализ данных на естественном языке, Text-to-SQL, многошаговые AI-агенты, автоматизация повторяющихся процессов.
- **Фокусируюсь на качестве и надёжности AI-систем**, а не только на генерации ответа: использую evaluation-наборы, golden sets, Recall@K, LLM-as-a-Judge, регрессионное тестирование, контроль контекста и token-бюджета.
- **Сочетаю AI и классическую разработку** — самостоятельно реализую backend и frontend, интегрирую LLM и внешние сервисы, работаю с базами данных и инфраструктурой.
- **Люблю превращать AI-прототипы в работающие продукты**, где важны не только возможности модели, но и скорость, воспроизводимость, устойчивость к ошибкам и удобство для конечного пользователя.
- **Постоянно исследую новые AI-подходы и инструменты**, проверяю гипотезы на практике и внедряю то, что действительно улучшает продукт.

ПРОФИЛЬ

AI / LLM Engineer с 7+ годами коммерческого опыта в разработке ПО. Специализируюсь на создании production-ready AI-решений: RAG-систем, AI-агентов и LLM-приложений на Python.

Разрабатываю **AI-системы полного цикла** — от обработки и поиска данных до генерации, валидации и оценки качества ответов. Реализую **RAG** и **hybrid search (BM25 + Vector Search, RRF)**, **embeddings**, **Agent Loop (ReAct)**, **Tool Calling**, **Text-to-SQL** и **мультиагентную оркестрацию**.

Фокусируюсь на **качестве и надёжности LLM-систем**: golden sets, Recall@K, LLM-as-a-Judge, регрессионное тестирование, обработка ошибок и self-correction, оптимизация контекста и token-бюджета. Работаю с облачными и локальными LLM через API, включая **GLM**, **OpenAI**, **Anthropic** и **Ollama**.

Имею сильную **software engineering базу** и опыт разработки end-to-end AI-продуктов: Python / FastAPI, PostgreSQL / ClickHouse, React / Next.js, Docker / Kubernetes / CI/CD. Способен самостоятельно пройти путь **от AI-прототипа до production-решения**.

Подробнее о моих проектах и опыте — на моём сайте: lyakoway.vercel.app

ОПЫТ РАБОТЫ

AI Engineer

MTC Web Services (MWS AI)

апрель 2024 — н. в. · Москва

ПРОЕКТЫ

RAG Chat — AI-ассистент с Retrieval-Augmented Generation

AI-ассистент для работы с документами — загружает PDF, Word и Excel, отвечает на вопросы по содержимому и предоставляет ссылки на исходные страницы и фрагменты.

- **RAG pipeline:** индексация документов → разбиение на фрагменты (tiktoken) → embeddings (fastembed) → гибридный поиск BM25 + вектора (RRF) → генерация ответа LLM → цитирование источников.
- **Архитектура:** Python / FastAPI → ChromaDB → fastembed → LLM API (GLM / OpenAI / Anthropic) / Ollama → SSE → React / TypeScript; SQLAlchemy — история диалогов.
- **Качество:** Recall@1 92% на golden set (evaluation-скрипт), LLM-as-judge 5.0/5.
- **GitHub / Демо:** github.com/lyakoway/ai-RAG-chat · lyakoway-rag-chat.hf.space

AI Data Pilot — мультиагентная аналитическая платформа

Автоматизирует путь от вопроса пользователя до готового аналитического результата.

- **Олег — AI-аналитик:** переводит вопросы на естественном языке в SQL, выполняет многошаговый анализ данных, выявляет динамику и отклонения, формирует таблицы, графики и аналитические выводы.
- **Ксюша — RAG-агент:** отвечает на вопросы по внутренней технической документации и загруженным документам (PDF, Word, Excel) с опорой на найденные источники.
- **Архитектура:** Python / FastAPI → SQLAlchemy → Agent Loop (ReAct) → Tool Calling → Text-to-SQL → SQL guard → PostgreSQL / ClickHouse → аналитический слой → SSE → React / TypeScript; RAG-ядро Ксюши — гибридный поиск BM25 + векторные эмбединги (fastembed) → LLM → цитирование источников.
- **GitHub / Демо:** github.com/lyakoway/ai-data-pilot · lyakoway-ai-data-pilot.hf.space

ОСНОВНЫЕ ЗАДАЧИ

- Проектировал и реализовывал AI-агентов для бизнес-сценариев — workflow, function / tool calling, оркестрация, обработка ошибок и восстановление после сбоев.
- Создавал AI-агентов для генерации контента и автоматизации процессов разработки.
- Разрабатывал и итеративно улучшал prompt-сценарии, тестировал их на точность, стабильность и edge cases.
- Формировал evaluation-наборы для регрессионной проверки качества ответов и контроля изменений в моделях и промптах.
- Оптимизировал работу с контекстом LLM — сжатие, приоритизация и управление token-бюджетом.
- Исследовал и внедрял подходы к оркестрации мультиагентных систем, следил за актуальными практиками индустрии.
- Участвовал в построении AI-платформы end-to-end — backend (Python, FastAPI), frontend (React / Next.js), инфраструктура (Docker, Kubernetes, CI/CD).
- Создавал скрипты и вспомогательные инструменты на Python / Bash, вёл документацию API и работал с open-source проектами.
- Исследовал новые подходы, проверял гипотезы и внедрял лучшие практики в production.

КЛЮЧЕВЫЕ РЕЗУЛЬТАТЫ

RAG Chat

- Продукт готов и используется в компании.
- Сокращает поиск информации с минут до секунд — пользователь задаёт вопрос своими словами и получает ответ с ссылкой на конкретный фрагмент исходного документа.
- Уменьшает количество повторяющихся обращений в поддержку — клиент самостоятельно получает ответы из технической документации без участия специалиста.
- Ускоряет работу с внутренними документами — сотрудники быстро находят нужные положения в регламентах, инструкциях и HR-политиках без ручного поиска по папкам.
- Ускоряет проверку юридических и финансовых документов — система находит нужные условия, суммы и показатели в договорах и отчётах за секунды.

НАВЫКИ

- Языки

PythonTypeScript / JavaScript
- LLM и AI-агенты

Multi-Provider LLM API (GLM / OpenAI / Anthropic / Ollama)

AI AgentsAgent Loop (ReAct)

Tool CallingText-to-SQL

Multi-Agent Orchestration

Prompt Engineering

Context / Token Optimization

Latency & Cost Tuning (TTFT, \$/запрос)
- RAG и поиск

RAGHybrid Search (BM25 + Vector)

RRFCross-Encoder Reranking

Chunking (tiktoken)

Кросс-языковой retrieval (RU / EN)

EmbeddingsfastembedChromaDB
- Evaluation и качество

Golden SetsRecall@K / MRR

LLM-as-a-Judge

Grounding / Anti-Hallucination

Observability & Monitoring (GA4 / Метрика / фидбек)

Prompt EvaluationRegression Testing

Edge Cases
- AI Data & Backend

FastAPISQLAlchemyPostgreSQL

ClickHouseSQLiteRedis

SQL Guard (read-only, таймауты)SSE

Node + Express
- Frontend

React + NextRedux ToolkitSvelte

Styled-ComponentsWebpackJest

Vite
- Инфраструктура

DockerKubernetesCI/CDGit

ОБРАЗОВАНИЕ

Магистратура — прикладная математика
МГСУ — Институт фундаментального
образования в 2014 год.

КЛЮЧЕВЫЕ РЕЗУЛЬТАТЫ

- AI Data Pilot

Продукт готов и используется в компании.

Сокращает подготовку отчётности с 2 часов до 2 минут — пользователь задаёт вопрос на естественном языке или запускает сохранённый сценарий одной кнопкой и получает готовые данные, график и вывод.

Убирает ручную подготовку SQL — агент самостоятельно переводит запрос пользователя в SQL, выполняет его и формирует результат анализа.

Снижает количество ошибок при работе с данными — агент проверяет результат выполнения, обнаруживает ошибки SQL, самостоятельно исправляет запрос и повторяет выполнение.

Автоматизирует путь от вопроса до готового аналитического вывода — система рассчитывает показатели, определяет динамику и отклонения, выделяет ключевые изменения и объясняет их пользователю.

Превращает повторяющиеся запросы в готовые сценарии — аналитик сохраняет часто используемый запрос и запускает его повторно без ручной подготовки SQL и настройки анализа.

Объединяет разнородные данные под одним интерфейсом — корпоративные БД (PostgreSQL, ClickHouse) и загруженные Excel-файлы доступны агенту одновременно, SQL-диалект подстраивается автоматически.

СТЕК

- RAG Chat

PythonFastAPISQLAlchemyRAGAI AgentsLLM APIChromaDBfastembed

OllamaSSEReactTypeScriptVite
- AI Data Pilot

PythonFastAPISQLAlchemyText-to-SQLAgent Loop (ReAct)Tool CallingRAG

BM25 + Vector SearchfastembedPostgreSQLClickHouseSSEReact 19

TypeScriptpytest

ПРОЦЕССЫ

- ScrumJiraConfluence

ДЕМО

- RAG Chat — <https://yakoway.vercel.app/portfolio/rag-chat>
- AI Data Pilot — <https://yakoway.vercel.app/portfolio/ai-data-pilot>

ОПЫТ РАБОТЫ

Senior Frontend Developer

февраль 2019 — апрель 2024 · Москва

MTC Web Services

ПРОЕКТЫ

- MTC Профиль

Модуль хранения и визуализации клиентских данных с управлением доступом для продуктов экосистемы.
- Экосистемные виджеты

Встраиваемый модуль навигации и персонализации для b2c/b2b-продуктов.

ОСНОВНЫЕ ЗАДАЧИ

- Разработка нового функционала и развитие существующих продуктов.
- Анализ требований, подготовка технических решений и проектирование архитектуры интеграционных сценариев.
- Разработка frontend-компонентов и переиспользуемых UI-решений с использованием Storybook.
- Рефакторинг и code review, повышение качества и поддерживаемости кодовой базы.
- Разработка unit- и интеграционных тестов, анализ и устранение production-инцидентов в рамках 3-й линии поддержки.
- Подготовка технической документации, менторство и помощь в адаптации новых сотрудников.

КЛЮЧЕВЫЕ РЕЗУЛЬТАТЫ

- Реализовал смену владельца профиля и модель управления связанными аккаунтами.
- Автоматизировал подтверждение данных пользователей через Госуслуги по биометрии.
- Реализовал полный цикл управления доступом и авторизацией — восстановление доступа, вход и историю изменений способов авторизации.
- Интегрировал оплату банковскими картами и экосистемные виджеты в цифровые продукты компании.

СТЕК

- ReactNext.jsTypeScriptRedux ToolkitSvelteStyled-ComponentsWebpackJestNode.js
- Express

ПРОЦЕССЫ

- ScrumJiraConfluence

ДЕМО

- MTC Профиль — id.mts.ru