

Алексей Мазуренко

AI / LLM Engineer

КОНТАКТЫ

Email: lyakoway@gmail.com

GitHub: github.com/lyakoway

LinkedIn: linkedin.com/in/alexey-mazurenko-63068941b

Сайт: lyakoway.vercel.app/contacts

В ЦИФРАХ

- ~2 000 документов · ~200 вопросов/день · Recall@1 87% held-out
- Подготовка отчётности: 2 часа → 2 минуты
- ~85% нормализованной точности SQL (held-out)
- Публичные GitHub-демо — RAG Chat и AI Data Pilot

ПРОФИЛЬ

AI / LLM-инженер с 7+ годами в разработке ПО, из них 2+ года — production LLM-системы в MTC Web Services (MWS AI) — AI-подразделении МТС, одного из крупнейших телеком-операторов России (~80 млн+ абонентов). Вывел в production два внутренних продукта: RAG-ассистент для документов (~2 000 документов, held-out Recall@1 53% dense-only → 87% hybrid) и мультиагентную аналитическую платформу (~85% нормализованной точности SQL), сократившую подготовку отчётности с 2 часов до 2 минут.

Продакшн развёрнут внутри МТС (~12 команд, ~200 RAG-вопросов/день). Публичные GitHub-демо — самостоятельные личные проекты того же класса задач, не исходный код МТС. Продовые данные под NDA. Для RAG в production — GLM-5.3-flash (TTFT ~2,5–3 с, стоимость vs GPT/Claude). OpenAI, Anthropic и Ollama взаимозаменяемы.

Веду путь от прототипа до production: Python / FastAPI, гибридный поиск, held-out evaluation, React / Next.js, Docker / Kubernetes / CI/CD.

Подробнее о моих проектах и опыте — на моём сайте: lyakoway.vercel.app

ОПЫТ РАБОТЫ

AI / LLM Engineer

апрель 2024 — н. в.

MTC Web Services (MWS AI)

ПРОЕКТЫ

RAG Chat — AI-ассистент с Retrieval-Augmented Generation

AI-ассистент для работы с документами — загружает PDF, Word и Excel, отвечает на вопросы по содержанию и предоставляет ссылки на исходные страницы и фрагменты.

- **RAG pipeline:** индексация документов → разбиение на фрагменты (tiktoken) → embeddings (fastembed) → гибридный поиск BM25 + векторов (RRF) → генерация ответа LLM → цитирование источников.
- **Три режима:** RAG Chat → AI Agent → Vector Search — переключение в одном приложении.
- **Архитектура:** Python / FastAPI → ChromaDB → fastembed → GLM-5.3-flash по умолчанию (OpenAI / Anthropic / Ollama) → SSE → React / TypeScript, SQLAlchemy — история диалогов.
- **Оценка:** held-out ~180 запросов, не использовавшихся для настройки промптов и retrieval. Гибрид BM25 + RRF: Recall@1 53% (dense-only) → 87%. Cross-encoder на fused top-k отклонён: RU/EN-дубликаты одного документа получали равный скор и вытесняли золотой чанк из fused top-k (~45 п.п. Recall@1, +~3 с).
- **Качество:** 63 pytest-теста + CI, TTFT ~2,5–3 с на GLM-5.3-flash.

AI Data Pilot — мультиагентная аналитическая платформа

Автоматизирует путь от вопроса пользователя до готового аналитического результата.

- **Олег — AI-аналитик:** переводит вопросы на естественном языке в SQL, выполняет многошаговый анализ данных, выявляет динамику и отклонения, формирует таблицы, графики и аналитические выводы.
- **Ксюша — RAG-агент:** отвечает на вопросы по внутренней технической документации и загруженным документам (PDF, Word, Excel) с опорой на найденные источники.
- **Архитектура:** Python / FastAPI → SQLAlchemy → Agent Loop (ReAct) → Tool Calling → Text-to-SQL → SQL guard → PostgreSQL / ClickHouse → аналитический слой → SSE → React / TypeScript, GLM-4.6 по умолчанию (OpenAI / Anthropic взаимозаменяемы), RAG-ядро Ксюши — гибридный поиск BM25 + векторные эмбединги (fastembed) → LLM → цитирование источников.
- **Качество:** 174 pytest-теста + CI, held-out SQL-оценка — ~98% execution (запрос выполнен), ~85% нормализованной точности результата (мультимножество значений без алиасов, ORDER BY и формата чисел — не string exact-match), самокоррекция при ошибке SQL (GLM-4.6).

ОСНОВНЫЕ ЗАДАЧИ

- Проектировал и выводил в production AI-агентов — tool calling, оркестрация, обработка ошибок и восстановление после сбоев.
- Строил и измерял RAG-пайплайны — гибридный BM25 + векторов, цитирование источников. Отклонил более медленный ранкер после проверки на held-out наборе.
- Формировал held-out evaluation-наборы — запросы не использовались для настройки промптов и retrieval — для регрессии поиска, промптов и моделей.
- Реализовал Text-to-SQL с SQL-guard и самокоррекцией запросов.
- Вёл сервисы AI-платформы end-to-end — backend (Python / FastAPI), frontend (React / Next.js), инфраструктура (Docker / Kubernetes / CI/CD).

КЛЮЧЕВЫЕ РЕЗУЛЬТАТЫ

RAG Chat

- Внутреннее использование в МТС (~2 000 документов, ~20 тыс. чанков, ~12 команд, ~200 вопросов/день). Публичное демо: личный проект, не код МТС, прод-данные под NDA.
- Held-out Recall@1 87% после гибрида BM25 + RRF.
- Сокращает поиск с минут до секунд по регламентам, договорам и HR-политикам.

AI Data Pilot

- Внутреннее использование в МТС (~15 аналитиков, ~80 сценариев отчётности/неделю по PostgreSQL, ClickHouse и Excel). Публичное демо: личный проект, не код МТС, продовые базы под NDA.
- Held-out SQL: ~98% execution, ~85% нормализованной точности (мультимножество значений, не exact-match), подготовка отчётности 2 часа → 2 минуты.
- Один интерфейс к PostgreSQL, ClickHouse и Excel, с автоподстройкой SQL-диалекта.

СТЕК

RAG Chat: Python, FastAPI, SQLAlchemy, RAG, AI Agents, LLM API, ChromaDB, fastembed, Ollama, SSE, React, TypeScript, Vite

AI Data Pilot: Python, FastAPI, SQLAlchemy, Text-to-SQL, Agent Loop (ReAct), Tool Calling, RAG, BM25 + Vector Search, fastembed, PostgreSQL, ClickHouse, SSE, React 19, TypeScript, pytest

ДЕМО

- RAG Chat — кейс — lyakoway.vercel.app/portfolio/rag-chat
- RAG Chat — код — github.com/lyakoway/ai-RAG-chat
- AI Data Pilot — кейс — lyakoway.vercel.app/portfolio/ai-data-pilot
- AI Data Pilot — код — github.com/lyakoway/ai-data-pilot

Senior Frontend Developer

февраль 2019 — апрель 2024

МТС Web Services

ПРОЕКТЫ

МТС Профиль

Модуль хранения и визуализации клиентских данных с управлением доступом для продуктов экосистемы.

Экосистемные виджеты

Встраиваемый модуль навигации и персонализации для b2c/b2b-продуктов.

КЛЮЧЕВЫЕ РЕЗУЛЬТАТЫ

- Реализовал смену владельца профиля и модель управления связанными аккаунтами.
- Автоматизировал подтверждение данных пользователей через Госуслуги по биометрии.
- Реализовал полный цикл управления доступом и авторизацией — восстановление доступа, вход и историю изменений способов авторизации.
- Интегрировал оплату банковскими картами и экосистемные виджеты в цифровые продукты компании.

СТЕК

React, Next.js, TypeScript, Redux Toolkit, Svelte, Styled-Components, Webpack, Jest, Node.js, Express

НАВЫКИ

LLM и AI-агенты: LLM API (OpenAI / Anthropic / GLM-5.3-flash / Ollama), AI-агенты, Agent Loop (ReAct), Tool Calling, Text-to-SQL, Мультиагентный роутер (2 специалиста), Prompt Engineering, Latency & Cost Tuning (TTFT, \$/запрос)

RAG и поиск: RAG, Hybrid Search (BM25 + Vector), RRF, Chunking (tiktoken), fastembed, ChromaDB, Цитирование источников

Evaluation и качество: Held-out eval (без утечки в настройку), Recall@K / MRR, LLM-as-a-Judge, Grounding / Anti-Hallucination, Prompt Evaluation, Regression Testing

AI Data & Backend: Python, FastAPI, SQLAlchemy, PostgreSQL, ClickHouse, SQL Guard (read-only, таймауты), SSE

Frontend и инфраструктура: React / Next.js, TypeScript, Docker, Kubernetes, CI/CD, Git

ОБРАЗОВАНИЕ

Магистратура — прикладная математика. МГСУ (Московский государственный строительный университет), 2014.