



Алексей Мазуренко

AI ENGINEER / LLM ENGINEER

КОНТАКТЫ

ТЕЛЕФОН
+7 (977) 270-09-30

EMAIL
lyakoway@gmail.com

ФОРМАТ
офис / гибрид / удалённо

САЙТ
lyakoway.vercel.app/contacts

ОБО МНЕ

- **AI-инженер** с 7+ годами коммерческого опыта в разработке ПО и сильной software engineering базой. Основной фокус — LLM-приложения, RAG-системы, AI-агенты и автоматизация рабочих процессов с помощью AI.
- **Создаю AI-продукты полного цикла** — от исследования задачи и проектирования AI-архитектуры до разработки, оценки качества, интеграции и вывода решения в production.
- **Работаю с реальными сценариями применения LLM:** поиск и работа с корпоративными знаниями, анализ данных на естественном языке, Text-to-SQL, многошаговые AI-агенты, автоматизация повторяющихся процессов.
- **Фокусируюсь на качестве и надёжности AI-систем**, а не только на генерации ответа: использую evaluation-наборы, golden sets, Recall@K, LLM-as-a-Judge, регрессионное тестирование, контроль контекста и token-бюджета.
- **Сочетаю AI и классическую разработку** — самостоятельно реализую backend и frontend, интегрирую LLM и внешние сервисы, работаю с базами данных и инфраструктурой.
- **Люблю превращать AI-прототипы в работающие продукты**, где важны не только возможности модели, но и скорость, воспроизводимость, устойчивость к ошибкам и удобство для конечного пользователя.
- **Постоянно исследую новые AI-подходы и инструменты**, проверяю гипотезы на практике и внедряю то, что действительно улучшает продукт.

ПРОФИЛЬ

AI / LLM Engineer с 7+ годами коммерческого опыта в разработке ПО. Специализируюсь на создании production-ready AI-решений: RAG-систем, AI-агентов и LLM-приложений на Python.

Разрабатываю **AI-системы полного цикла** — от обработки и поиска данных до генерации, валидации и оценки качества ответов. Реализую **RAG и hybrid search (BM25 + Vector Search, RRF), embeddings, Agent Loop (ReAct), Tool Calling, Text-to-SQL** и мультиагентную оркестрацию.

Фокусируюсь на **качестве и надёжности LLM-систем**: golden sets, Recall@K, LLM-as-a-Judge, регрессионное тестирование, обработка ошибок и self-correction, оптимизация контекста и token-бюджета. Работаю с облачными и локальными LLM через API, включая **GLM, OpenAI, Anthropic и Ollama**.

Имею сильную **software engineering базу** и опыт разработки end-to-end AI-продуктов: Python / FastAPI, PostgreSQL / ClickHouse, React / Next.js, Docker / Kubernetes / CI/CD. Способен самостоятельно пройти путь **от AI-прототипа до production-решения**.

Подробнее о моих проектах и опыте — на моём сайте: lyakoway.vercel.app

ОПЫТ РАБОТЫ

AI Engineer

MTC Web Services (MWS AI)

апрель 2024 — н. в. · Москва

ПРОЕКТЫ

RAG Chat — AI-ассистент с Retrieval-Augmented Generation

AI-ассистент для работы с документами — загружает PDF, Word и Excel, отвечает на вопросы по содержимому и предоставляет ссылки на исходные страницы и фрагменты.

- **RAG pipeline:** индексация документов → разбиение на фрагменты (tiktoken) → embeddings (fastembed) → гибридный поиск BM25 + вектора (RRF) → генерация ответа LLM → цитирование источников.
- **Архитектура:** Python / FastAPI → ChromaDB → fastembed → LLM API (GLM / OpenAI / Anthropic) / Ollama → SSE → React / TypeScript; SQLAlchemy — история диалогов.
- **Качество:** Recall@1 92% на golden set (evaluation-скрипт), LLM-as-judge 5.0/5.
- **GitHub / Демо:** github.com/lyakoway/ai-RAG-chat · lyakoway-rag-chat.hf.space

AI Data Pilot — мультиагентная аналитическая платформа

Автоматизирует путь от вопроса пользователя до готового аналитического результата.

- **Олег — AI-аналитик:** переводит вопросы на естественном языке в SQL, выполняет многошаговый анализ данных, выявляет динамику и отклонения, формирует таблицы, графики и аналитические выводы.
- **Ксюша — RAG-агент:** отвечает на вопросы по внутренней технической документации и загруженным документам (PDF, Word, Excel) с опорой на найденные источники.
- **Архитектура:** Python / FastAPI → SQLAlchemy → Agent Loop (ReAct) → Tool Calling → Text-to-SQL → SQL guard → PostgreSQL / ClickHouse → аналитический слой → SSE → React / TypeScript; RAG-ядро Ксюши — гибридный поиск BM25 + векторные эмбединги (fastembed) → LLM → цитирование источников.
- **GitHub / Демо:** github.com/lyakoway/ai-data-pilot · lyakoway-ai-data-pilot.hf.space

ОСНОВНЫЕ ЗАДАЧИ

- Проектировал и реализовывал AI-агентов для бизнес-сценариев — workflow, function / tool calling, оркестрация, обработка ошибок и восстановление после сбоев.
- Создавал AI-агентов для генерации контента и автоматизации процессов разработки.
- Разрабатывал и итеративно улучшал prompt-сценарии, тестировал их на точность, стабильность и edge cases.
- Формировал evaluation-наборы для регрессионной проверки качества ответов и контроля изменений в моделях и промптах.
- Оптимизировал работу с контекстом LLM — сжатие, приоритизация и управление token-бюджетом.
- Исследовал и внедрял подходы к оркестрации мультиагентных систем, следил за актуальными практиками индустрии.
- Участвовал в построении AI-платформы end-to-end — backend (Python, FastAPI), frontend (React / Next.js), инфраструктура (Docker, Kubernetes, CI/CD).
- Создавал скрипты и вспомогательные инструменты на Python / Bash, вёл документацию API и работал с open-source проектами.
- Исследовал новые подходы, проверял гипотезы и внедрял лучшие практики в production.

КЛЮЧЕВЫЕ РЕЗУЛЬТАТЫ

RAG Chat

- Продукт готов и используется в компании.
- Сокращает поиск информации с минут до секунд — пользователь задаёт вопрос своими словами и получает ответ с ссылкой на конкретный фрагмент исходного документа.
- Уменьшает количество повторяющихся обращений в поддержку — клиент самостоятельно получает ответы из технической документации без участия специалиста.
- Ускоряет работу с внутренними документами — сотрудники быстро находят нужные положения в регламентах, инструкциях и HR-политиках без ручного поиска по папкам.
- Ускоряет проверку юридических и финансовых документов — система находит нужные условия, суммы и показатели в договорах и отчётах за секунды.

НАВЫКИ

- Языки
 - Python
 - TypeScript / JavaScript
- LLM и AI-агенты
 - Multi-Provider LLM API (GLM / OpenAI / Anthropic / Ollama)
 - AI Agents
 - Agent Loop (ReAct)
 - Tool Calling
 - Text-to-SQL
 - Multi-Agent Orchestration
 - Prompt Engineering
 - Context / Token Optimization
 - Latency & Cost Tuning (TTFT, \$/запрос)
- RAG и поиск
 - RAG
 - Hybrid Search (BM25 + Vector)
 - RRF
 - Cross-Encoder Reranking
 - Chunking (tiktoken)
 - Кросс-языковой retrieval (RU / EN)
 - Embeddings
 - fastembed
 - ChromaDB
- Evaluation и качество
 - Golden Sets
 - Recall@K / MRR
 - LLM-as-a-Judge
 - Grounding / Anti-Hallucination
 - Observability & Monitoring (GA4 / Метрика / фидбек)
 - Prompt Evaluation
 - Regression Testing
 - Edge Cases
- AI Data & Backend
 - FastAPI
 - SQLAlchemy
 - PostgreSQL
 - ClickHouse
 - SQLite
 - Redis
 - SQL Guard (read-only, таймауты)
 - SSE
 - Node + Express
- Frontend
 - React + Next
 - Redux Toolkit
 - Svelte
 - Styled-Components
 - Webpack
 - Jest
 - Vite
- Инфраструктура
 - Docker
 - Kubernetes
 - CI/CD
 - Git

ОБРАЗОВАНИЕ

Магистратура — прикладная математика МГСУ — Институт фундаментального образования в 2014 год.

КЛЮЧЕВЫЕ РЕЗУЛЬТАТЫ

- AI Data Pilot
 - Продукт готов и используется в компании.
 - Сокращает подготовку отчётности с 2 часов до 2 минут — пользователь задаёт вопрос на естественном языке или запускает сохранённый сценарий одной кнопкой и получает готовые данные, график и вывод.
 - Убирает ручную подготовку SQL — агент самостоятельно переводит запрос пользователя в SQL, выполняет его и формирует результат анализа.
 - Снижает количество ошибок при работе с данными — агент проверяет результат выполнения, обнаруживает ошибки SQL, самостоятельно исправляет запрос и повторяет выполнение.
 - Автоматизирует путь от вопроса до готового аналитического вывода — система рассчитывает показатели, определяет динамику и отклонения, выделяет ключевые изменения и объясняет их пользователю.
 - Превращает повторяющиеся запросы в готовые сценарии — аналитик сохраняет часто используемый запрос и запускает его повторно без ручной подготовки SQL и настройки анализа.
 - Объединяет разнородные данные под одним интерфейсом — корпоративные БД (PostgreSQL, ClickHouse) и загруженные Excel-файлы доступны агенту одновременно, SQL-диалект подстраивается автоматически.

СТЕК

- RAG Chat
 - Python
 - FastAPI
 - SQLAlchemy
 - RAG
 - AI Agents
 - LLM API
 - ChromaDB
 - fastembed
 - Ollama
 - SSE
 - React
 - TypeScript
 - Vite
- AI Data Pilot
 - Python
 - FastAPI
 - SQLAlchemy
 - Text-to-SQL
 - Agent Loop (ReAct)
 - Tool Calling
 - RAG
 - BM25 + Vector Search
 - fastembed
 - PostgreSQL
 - ClickHouse
 - SSE
 - React 19
 - TypeScript
 - pytest

ПРОЦЕССЫ

- Scrum
- Jira
- Confluence

ДЕМО

- RAG Chat — <https://yakoway.vercel.app/portfolio/rag-chat>
- AI Data Pilot — <https://yakoway.vercel.app/portfolio/ai-data-pilot>

ОПЫТ РАБОТЫ

Senior Frontend Developer февраль 2019 — апрель 2024 · Москва
MTC Web Services

ПРОЕКТЫ

- MTC Профиль
 - Модуль хранения и визуализации клиентских данных с управлением доступом для продуктов экосистемы.

Экосистемные виджеты

Встраиваемый модуль навигации и персонализации для b2c/b2b-продуктов.

ОСНОВНЫЕ ЗАДАЧИ

- Разработка нового функционала и развитие существующих продуктов.
- Анализ требований, подготовка технических решений и проектирование архитектуры интеграционных сценариев.
- Разработка frontend-компонентов и переиспользуемых UI-решений с использованием Storybook.
- Рефакторинг и code review, повышение качества и поддерживаемости кодовой базы.
- Разработка unit- и интеграционных тестов, анализ и устранение production-инцидентов в рамках 3-й линии поддержки.
- Подготовка технической документации, менторство и помощь в адаптации новых сотрудников.

КЛЮЧЕВЫЕ РЕЗУЛЬТАТЫ

- Реализовал смену владельца профиля и модель управления связанными аккаунтами.
- Автоматизировал подтверждение данных пользователей через Госуслуги по биометрии.
- Реализовал полный цикл управления доступом и авторизацией — восстановление доступа, вход и историю изменений способов авторизации.
- Интегрировал оплату банковскими картами и экосистемные виджеты в цифровые продукты компании.

СТЕК

- React
- Next.js
- TypeScript
- Redux Toolkit
- Svelte
- Styled-Components
- Webpack
- Jest
- Node.js
- Express

ПРОЦЕССЫ

- Scrum
- Jira
- Confluence

ДЕМО

- MTC Профиль — id.mts.ru